þÿKi¿n trœc Transformer là n`n t£ng cÑt lıi çña cÆc mô hình ngôn ngï lÛ
þÿModels - LLMs) hi¨n ¡i nhÝc¡ ch¿ Self-Attention xí lý song song toàn
þÿv n b£n.

þÿKø thu›t tinh chÉnh có giÆm sÆt (Supervised Fine-Tuning - SFT) giœ
þÿngï lÛn h˝c cÆch tuân thç t›p chÉd«n chuyŒn bi¨t và xu¥t dï li¨u œng
þÿc¥u trœc JSON.

þÿPh°¡ng phÆp LoRA (Low-Rank Adaptation) óng b ng ma tr›n tr˝ng sÑ
þÿc•p ma tr›n phân rª h¡ng th¥p A, B vào cÆc t§ng tuy¿n tính, giœp gi£
þÿl°ªng tham sÑc§n c›p nh›t.

þÿKø thu›t QLoRA k¿t hªp l°ªng tí hóa tr˝ng sÑgÑc xuÑng kiˆu dï li¨u 4-b
þÿ(NF4), sí dång Double Quantization và Paged Optimizers giœp ti¿t ki
þÿnhÛ VRAM trŒn mÆy chç GPU.

þÿThang o nh›n thØc Bloom chia câu h˘i kiˆm tra Ænh giÆ thành cÆc c
þÿ¿n cao gÓm Nh›n bi¿t, Thông hiˆu, V›n dång và V›n dång cao nh–m ph
þÿxÆc n ng læc ng°Ýi h˝c.

þÿTrong bài toÆn sinh ` thi trflc nghi¨m tæ Ùng, cÆc ph°¡ng Æn nhi¯u
þÿc§n có Ùdài và thu›t ngï t°¡ng °¡ng Æp Æn œng ˆ trÆnh vi¨c h˝c si
þÿdæa trŒn Ùdài câu.